

RAG Deployment on AWS

EU AI Act Use Case

Que es RAG?

El Problema

Los LLMs alucinan. Inventan hechos, crean citas falsas y su conocimiento esta congelado en el momento del entrenamiento.

Para texto regulatorio de alto impacto como el EU AI Act, esto no es aceptable.


La Solucion RAG

La Generacion Aumentada por Recuperacion fundamenta cada respuesta en texto real del documento.

En lugar de depender de la memoria del modelo, el sistema obtiene los pasajes mas relevantes del Acta, razona sobre ellos y cita los fragmentos fuente exactos que utilizo.

Cada respuesta es verificable. Cada afirmacion tiene una cita.

Arquitectura del Sistema



Stack Tecnológico



AWS Bedrock AgentCore

Runtime serverless de agentes -- despliega contenedor Docker en infraestructura gestionada



Bedrock Knowledge Bases

Almacenamiento vectorial gestionado + recuperacion -- S3 + Titan Embeddings + OpenSearch



Amazon Nova Lite

LLM multimodal rapido y economico para razonamiento via Bedrock Converse API



LangGraph

Orquestador StateGraph -- conecta agentes con estado tipado y enrutamiento de aristas



Streamlit

Interfaz de chat en ECS -- llama a invoke_agent_runtime y muestra indicadores de fundamentacion



CloudWatch + OTEL

Observabilidad -- logs, trazas y metricas en todas las etapas del pipeline

Conclusiones Clave



AgentCore hace el despliegue trivial

Define tu agente en agentcore.json, sube una imagen Docker -- AgentCore gestiona el escalado, enrutamiento e IAM.



LangGraph = logica de agentes legible

StateGraph convierte la orquestacion en un DAG limpio. Depurar agentes se convierte en depurar un grafo.



La validacion no es negociable

Sin un validador no puedes confiar en la salida RAG. Las comprobaciones de citas hacen visibles las alucinaciones.



Los documentos legales son el objetivo RAG mas dificil

Las referencias cruzadas, la terminologia precisa y los requisitos de citas hacen del EU AI Act una prueba real de calidad de recuperacion.

Performance: Medicion y Optimizacion

**¿Como medimos el
performance de un RAG?**

**¿Como optimizamos
parametros para mejorar el
performance?**